



**ΠΑΝΕΠΙΣΤΗΜΙΟ ΔΥΤΙΚΗΣ ΑΤΤΙΚΗΣ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΠΛΗΡΟΦΟΡΙΚΗΣ ΚΑΙ
ΥΠΟΛΟΓΙΣΤΩΝ**

Μάθημα: Διαχείριση Δεδομένων Μεγάλης Κλίμακας

**Υλοποίηση End-to-End Συστήματος Ανάλυσης Δεδομένων
και Μηχανικής Μάθησης για την Πρόβλεψη Διαβήτη**

Υλοποίηση:

Βαγενάς Νικόλαος (ΑΜ: 19390025)

Διδάσκων Καθηγητής:

Παναγιώτης Αργυράκης

Περίληψη

Η παρούσα εργασία πραγματεύεται τη σχεδίαση και υλοποίηση ενός ολοκληρωμένου (end-to-end) συστήματος εξόρυξης δεδομένων και μηχανικής μάθησης με σκοπό την έγκαιρη πρόβλεψη του σακχαρώδη διαβήτη. Χρησιμοποιώντας ένα κλινικό σύνολο δεδομένων 100.000 ασθενών, εφαρμόστηκαν μέθοδοι προεπεξεργασίας, καθαρισμού και κανονικοποίησης χαρακτηριστικών. Στο στάδιο της επιβλεπόμενης μάθησης, αναπτύχθηκαν και συγκρίθηκαν δύο μοντέλα ταξινόμησης: ένα Δέντρο Απόφασης (Decision Tree) και ένας Απλοϊκός Bayes (Naive Bayes). Τα πειραματικά αποτελέσματα έδειξαν την ανωτερότητα του Δέντρου Απόφασης, το οποίο πέτυχε ακρίβεια (Accuracy) 97.16% και απόλυτη πιστότητα (Precision 100.00%). Παράλληλα, ως προηγμένη τεχνική μη επιβλεπόμενης μάθησης, εφαρμόστηκε ο αλγόριθμος K-Means Clustering ($K = 3$), ο οποίος επέτρεψε την αυτόματη ομαδοποίηση των ασθενών και την αναγνώριση πληθυσμιακών προφίλ υψηλού κινδύνου, αναδεικνύοντας τον συνδυασμό παχυσαρκίας και μέσης ηλικίας ως τον πλέον επιβαρυντικό παράγοντα. Τέλος, εξετάζεται η δυνατότητα κλιμάκωσης του συστήματος σε περιβάλλον μεγάλων δεδομένων (Big Data) μέσω του Apache Spark. Τα συμπεράσματα της εργασίας υπογραμμίζουν την αξία των predictive μοντέλων στην υποστήριξη κλινικών αποφάσεων και την προληπτική ιατρική.

Περιεχόμενα

1	Εισαγωγή & Σκόπος της Εργασίας	3
1.1	Κατανομή Ρόλων και Μεθοδολογία	3
2	Data Understanding & Preprocessing	4
2.1	Περιγραφή του Dataset	4
2.2	Καθαρισμός Δεδομένων (Data Cleaning)	4
2.3	Feature Engineering & Scaling	4
3	Exploratory Data Analysis (EDA)	5
3.1	Κατανομή Κλάσης Στόχου	5
3.2	Πίνακας Συσχέτισης (Correlation Matrix)	5
4	Εφαρμογή Αλγορίθμων Ταξινόμησης	7
4.1	Μοντέλο 1: Δέντρο Απόφασης (Decision Tree)	7
4.2	Μοντέλο 2: Απλοϊκός Bayes (Naive Bayes)	7
5	Αξιολόγηση και Σύγκριση Μοντέλων	8
5.1	Μετρικές Απόδοσης	8
5.2	Καμπύλη ROC και Συμπεράσματα Σύγκρισης	8
6	Advanced Technique: Clustering (K-Means)	10
6.1	Μέθοδος του Αγκώνα (Elbow Method)	10
6.2	Στατιστική Ανάλυση & Insights των Clusters	10
7	Προσέγγιση Big Data (Spark / Scale-up)	12
8	Συμπεράσματα	13

1. Εισαγωγή & Σκόπος της Εργασίας

Η παρούσα εξαμηνιαία εργασία εντάσσεται στο πλαίσιο του μαθήματος “Διαχείριση Δεδομένων Μεγάλης Κλίμακας” και έχει ως αντικείμενο την ανάπτυξη ενός ολοκληρωμένου συστήματος ανάλυσης δεδομένων και μηχανικής μάθησης για την πρόβλεψη της εμφάνισης διαβήτη σε ασθενείς.

Ο κύριος στόχος είναι η αξιοποίηση ιστορικών κλινικών δεδομένων για την εκπαίδευση μοντέλων ταξινόμησης (Classification), καθώς και η εφαρμογή προηγμένων τεχνικών ομαδοποίησης (Clustering) για την αναγνώριση ομάδων υψηλού κινδύνου στον πληθυσμό.

1.1 Κατανομή Ρόλων και Μεθοδολογία

Παρότι η εργασία υλοποιήθηκε ατομικά, ακολουθήθηκε η προβλεπόμενη δομή ρόλων για τη διασφάλιση της ποιότητας του λογισμικού:

- **Data Engineer:** Υπεύθυνος για τη φόρτωση, τον καθαρισμό, τη διαχείριση των διπλότυπων, το Label Encoding κατηγορικών μεταβλητών και το Feature Scaling.
- **Data Analyst:** Υπεύθυνος για την εξαγωγή στατιστικών στοιχείων και την οπτικοποίηση των δεδομένων (Exploratory Data Analysis - EDA).
- **ML Engineer:** Υπεύθυνος για τον διαχωρισμό των δεδομένων, την εκπαίδευση των μοντέλων, την αξιολόγηση μέσω μετρικών και τη σύγκριση των αποτελεσμάτων.

2. Data Understanding & Preprocessing

2.1 Περιγραφή του Dataset

Για τις ανάγκες του project επιλέχθηκε το **Diabetes Prediction Dataset** από την πλατφόρμα Kaggle. Το dataset αποτελείται αρχικά από 100.000 εγγραφές (γραμμές) και 9 στήλες (χαρακτηριστικά), οι οποίες περιλαμβάνουν δημογραφικά στοιχεία (ηλικία, φύλο), ιατρικό ιστορικό (υπέρταση, καρδιοπάθειες, ιστορικό καπνίσματος) και κλινικές μετρήσεις (BMI, επίπεδο HbA1c, επίπεδο γλυκόζης στο αίμα).

2.2 Καθαρισμός Δεδομένων (Data Cleaning)

Κατά το στάδιο της μηχανικής δεδομένων, εκτελέστηκαν οι εξής ενέργειες:

1. **Έλεγχος Ελλιπών Τιμών:** Με τη χρήση της συνάρτησης `isnull().sum()` διαπιστώθηκε ότι δεν υπήρχαν ελλιπείς τιμές στις στήλες του dataset.
2. **Αφαίρεση Διπλότυπων:** Εντοπίστηκαν και αφαιρέθηκαν οι διπλότυπες εγγραφές με τη συνάρτηση `drop_duplicates()`, διασφαλίζοντας την ακεραιότητα της εκπαίδευσης των μοντέλων χωρίς την εισαγωγή στατιστικής μεροληψίας (bias).

2.3 Feature Engineering & Scaling


Οι κατηγορικές μεταβλητές `gender` και `smoking_history` μετατράπηκαν σε αριθμητικές τιμές με τη χρήση του `LabelEncoder` της βιβλιοθήκης `Scikit-Learn`. Στην συνέχεια, εφαρμόστηκε ο αλγόριθμος `StandardScaler` στις αριθμητικές μεταβλητές, ώστε να αποκτήσουν μέση τιμή 0 και τυπική απόκλιση 1. Η διαδικασία αυτή είναι κρίσιμη για αλγορίθμους που βασίζονται σε αποστάσεις ή στην κλίση του σφάλματος.

3. Exploratory Data Analysis (EDA)

Στο στάδιο της διερευνητικής ανάλυσης δεδομένων, πραγματοποιήθηκε οπτικοποίηση της κλάσης στόχου (diabetes) και των συσχετίσεων μεταξύ των χαρακτηριστικών.

3.1 Κατανομή Κλάσης Στόχου


Διαπιστώθηκε ότι το dataset παρουσιάζει έντονη ανισορροπία κλάσεων (imbalance), καθώς η συντριπτική πλειοψηφία των δειγμάτων αφορά μη διαβητικούς ασθενείς, γεγονός που αντικατοπτρίζει την πραγματική κατανομή της νόσου στον γενικό πληθυσμό.



Σχήμα 3.1: Κατανομή της μεταβλητής στόχου (Διαβήτης).

3.2 Πίνακας Συσχέτισης (Correlation Matrix)

Μέσω του διαγράμματος Heatmap, παρατηρήθηκε ότι τα χαρακτηριστικά `blood_glucose_level` και `HbA1c_level` εμφανίζουν την υψηλότερη θετική συσχέτιση με την εμφάνιση διαβήτη, αποτελώντας τις πιο σημαντικές μεταβλητές για την πρόβλεψη.



Σχήμα 3.2: Πίνακας Συσχέτισης Χαρακτηριστικών.

4. Εφαρμογή Αλγορίθμων Ταξινόμησης

Τα δεδομένα χωρίστηκαν σε σύνολο εκπαίδευσης (Train Set - 80%) και σύνολο ελέγχου (Test Set - 20%). Υλοποιήθηκαν υποχρεωτικά δύο μοντέλα ταξινόμησης.

4.1 Μοντέλο 1: Δέντρο Απόφασης (Decision Tree)

Το Δέντρο Απόφασης εκπαιδεύτηκε με περιορισμό μέγιστου βάθους (`max_depth=5`) για την αποτροπή του φαινομένου της υπερεκπαίδευσης. Το μοντέλο προσφέρει εξαιρετική ερμηνευσιμότητα, καθώς επιτρέπει την εξαγωγή κανόνων διάγνωσης.

4.2 Μοντέλο 2: Απλοϊκός Bayes (Naive Bayes)

Υλοποιήθηκε ο αλγόριθμος Gaussian Naive Bayes, ο οποίος βασίζεται στην πιθανοθεωρητική προσέγγιση του κανόνα του Bayes, υποθέτοντας ωστόσο τη στατιστική ανεξαρτησία μεταξύ των χαρακτηριστικών.

5. Αξιολόγηση και Σύγκριση Μοντέλων

5.1 Μετρικές Απόδοσης


Η αξιολόγηση των μοντέλων πραγματοποιήθηκε με βάση τις μετρικές Accuracy, Precision και Recall στο Test Set.

Πίνακας 5.1: Συγκριτικός Πίνακας Απόδοσης Μοντέλων

Μοντέλο	Accuracy	Precision	Recall
Decision Tree	97.16%	100.00%	67.81%
Naive Bayes	90.10%	45.67%	64.68%

5.2 Καμπύλη ROC και Συμπεράσματα Σύγκρισης

Η σύγκριση των δύο μοντέλων αναδεικνύει την ανωτερότητα του Δέντρου Απόφασης για τη συγκεκριμένη κλινική εφαρμογή. Ο αλγόριθμος Naive Bayes παρουσιάζει σημαντική υστέρηση στην πιστότητα (Precision 45.67%), πράγμα που σημαίνει ότι περισσότερες από τις μισές θετικές του διαγνώσεις είναι λανθασμένες (False Positives). Αυτό οφείλεται στην εγγενή αδυναμία του αλγορίθμου να αναγνωρίσει τις συσχετίσεις μεταξύ των ιατρικών χαρακτηριστικών (π.χ. τη σχέση ηλικίας και BMI), θεωρώντας τα στατιστικά ανεξάρτητα. Αντίθετα, το Decision Tree, με Accuracy 97.16% και Precision 100.00%, αποδεικνύεται ένα ασφαλές μοντέλο, καθώς αποφεύγει πλήρως το σφάλμα της λανθασμένης διάγνωσης σε υγιείς ανθρώπους.




Σχήμα 5.1: Σύγκριση Καμπυλών ROC.

6. Advanced Technique: Clustering (K-Means)

Ως προηγμένη τεχνική (Advanced Technique) στο πλαίσιο της εργασίας, επιλέχθηκε η εφαρμογή μη επιβλεπόμενης μάθησης (Unsupervised Learning) και συγκεκριμένα ο αλγόριθμος ομαδοποίησης **K-Means**. Στόχος ήταν η αυτόματη αναγνώριση διακριτών προφίλ ασθενών με βάση αποκλειστικά δύο χαρακτηριστικά: την Ηλικία (age) και τον Δείκτη Μάζας Σώματος (bmi), χωρίς το μοντέλο να γνωρίζει εκ των προτέρων την ετικέτα του διαβήτη.

6.1 Μέθοδος του Αγκώνα (Elbow Method)

Για τον καθορισμό του βέλτιστου αριθμού συστάδων (Clusters), εφαρμόστηκε η Μέθοδος του Αγκώνα (Elbow Method). Υπολογίστηκε το άθροισμα των τετραγώνων των αποστάσεων εντός των συστάδων (WCSS) για τιμές του K από 1 έως 10. Το παραχθέν γράφημα υπέδειξε ως βέλτιστο σημείο κάμψης (“αγκώνα”) την τιμή $K = 3$, η οποία και επιλέχθηκε για την τελική ομαδοποίηση.



Σχήμα 6.1: Διάγραμμα Μεθόδου Αγκώνα για την εύρεση του βέλτιστου K .

6.2 Στατιστική Ανάλυση & Insights των Clusters


Η εκτέλεση του αλγορίθμου K-Means με $K = 3$ οδήγησε στον διαχωρισμό του πληθυσμού σε τρεις σαφείς ομάδες με τα εξής στατιστικά χαρακτηριστικά (μέσοι όροι):

Πίνακας 6.1: Στατιστικά Στοιχεία και Προφίλ Ανά Συστάδα (Cluster)

Συστάδα	Μέση Ηλικία	Μέσο BMI	Ποσοστό Διαβήτη	Χαρακτηρισμός Προφίλ
Cluster 0	19.00 έτη	22.98	0.95%	Νέοι / Φυσιολογικό Βάρος (Χαμηλό Ρίσκο)
Cluster 1	45.78 έτη	38.58	18.65%	Μέσης Ηλικίας / Παχυσαρκία (Υψηλό Ρίσκο)
Cluster 2	59.36 έτη	26.99	11.94%	Ηλικιωμένοι / Ήπια Υπέρβαροι (Μεσαίο Ρίσκο)

Τα αποτελέσματα προσφέρουν πολύτιμα κλινικά συμπεράσματα (Insights). Παρατηρείται ότι το **Cluster 1**, το οποίο περιλαμβάνει άτομα μέσης ηλικίας (45.7 έτη) αλλά με πολύ υψηλό δείκτη παχυσαρκίας (BMI 38.58), παρουσιάζει το υψηλότερο ποσοστό εμφάνισης διαβήτη στο dataset (**18.65%**). Το ποσοστό αυτό είναι σχεδόν διπλάσιο από εκείνο του **Cluster 2** (11.94%), το οποίο αφορά σημαντικά γηραιότερους ανθρώπους (59.3 έτη) αλλά με χαμηλότερο BMI (26.99).

Το εύρημα αυτό αποδεικνύει ότι ο υψηλός Δείκτης Μάζας Σώματος (παχυσαρκία) αποτελεί ακόμα πιο επιβαρυντικό παράγοντα για την εκδήλωση διαβήτη συγκριτικά με την ηλικιακή γήρανση, επιβεβαιώνοντας την αξία του K-Means στην αυτόματη ανίχνευση ομάδων υψηλού κινδύνου.



Σχήμα 6.2: Οπτικοποίηση των 3 συστάδων (Clusters) ασθενών.

7. Προσέγγιση Big Data (Spark / Scale-up)

Στο πλαίσιο των απαιτήσεων για Big Data, αναλύεται η αρχιτεκτονική μεταφοράς του παρόντος pipeline σε περιβάλλον **Apache Spark (PySpark)** σε περίπτωση που ο όγκος των δεδομένων αυξανόταν σε εκατομμύρια εγγραφές (π.χ. εθνικά συστήματα υγείας).

Η επεξεργασία θα βασιζόταν σε Spark DataFrames για κατανεμημένη επεξεργασία στη μνήμη (In-memory distributed computing). Για το feature engineering θα γινόταν χρήση των κλάσεων `StringIndexer` και `VectorAssembler` του Spark MLlib, ενώ η εκπαίδευση του ταξινομητή θα πραγματοποιούνταν παράλληλα στους κόμβους του cluster μέσω της βιβλιοθήκης `pyspark.ml.classification.DecisionTreeClassifier`.

8. Συμπεράσματα

Η παρούσα εργασία επέτυχε την ανάπτυξη ενός end-to-end συστήματος data mining. Τα συμπεράσματα δείχνουν ότι η χρήση δομημένων ιατρικών δεδομένων σε συνδυασμό με αλγόριθμους όπως τα Δέντρα Απόφασης μπορεί να προσφέρει υψηλή διαγνωστική ακρίβεια.

Οι πρακτικές εφαρμογές της μελέτης περιλαμβάνουν την ενσωμάτωση τέτοιων μοντέλων σε Συστήματα Υποστήριξης Κλινικών Αποφάσεων (CDSS) για την υποβοήθηση του ιατρικού προσωπικού, καθώς και τη δημιουργία ψηφιακών εργαλείων προληπτικής υγείας για τον έγκαιρο εντοπισμό πολιτών υψηλού κινδύνου.

Σύνδεσμος Αποθετηρίου GitHub: <https://github.com/Vagenikos/Diabetes-mining-project>

Βιβλιογραφία

- [1] Kaggle Dataset, “Diabetes Prediction Dataset,” [Online]. Available: <https://www.kaggle.com/>. [Accessed: 11-Jun-2026].
- [2] F. Pedregosa *et al.*, “Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [3] M. Zaharia *et al.*, “Apache Spark: A Unified Engine for Big Data Processing,” *Communications of the ACM*, vol. 59, no. 11, pp. 56–65, 2016.
- [4] J. Han, M. Kamber, and J. Pei, *Data Mining: Concepts and Techniques*, 3rd ed. San Francisco, CA: Morgan Kaufmann, 2011.